

Greppe eller søke i korpus:	2
Kjør en tekst og få ut ord som mangler	2
Missinglists	2
Generere/oppdatere nobfkv og fkvnob:	3
Hvor mange ord er det i ordboka?	4
Hvor mange ord er det i korpus?	5
Finn ord som finnes i en ordbok, men mangler i den andre	6
Script som automatisk lager xml-oppsettet til ordboka fra en tabliste:	7
Legge til ord fra sanakirja til lexc	7
Tastatursnarveier	8
Hvordan klone repositorie (sjekke ut til egen maskin)	8
Korpuskommandoer	9
Greppe ord som mangler i ordboka uten å miste oversettelsene / resten av tekstlinja:	10
Speller-arbeid:	10

## Greppe eller søke i korpus:

```
grep -r 'detjegvilfinne' filnavn.txt
grep -rl 'detjegvilfinne' filnavn.txt (vis bare filnavnene)
grep -rl (bruk den også hvis den spør om directory):
grep -rl 'detjegvilfinne' corpus-fkv/converted/ (søk i hele converted-mappa)
```

## Kjør en tekst og få ut ord som mangler

```
cat tekst.txt | preprocess | ufkv | cut -f2|cut -d"+" -f1|uniq | sort|uniq -c|sort -nr|cut
-c6-|fkvnob | grep "+?" | less
```

vs. gammel kommando for egen fil:

```
cat text.txt | preprocess | ufkv | grep '+?' |cut -f1 | sort | uniq -c | sort -nr | less
```

```
cat tekst.txt | preprocess | ufkv | cut -f2|cut -d"+" -f1|uniq | sort|uniq -c|sort -nr|cut
-c6-|fkvnob | grep "+?" | less (näyttää sanat ja ufkv:n kysymysmerkit, sanojen
aakkosjärjestyksessä)
```

```
cat text.txt | preprocess | ufkv | grep '+?' |cut -f1 | sort | uniq -c | sort -nr |
less (tämä näyttää vain sanat, frekventtiyksen järjestyksessä)
```

Kommandoforklaring:

```
cat ~/Downloads/mandat.txt| # ota teksti
preprocess|          # yksi sana per rivi
unob|                # norjan analysaattori
cut -f2|             # ota lemma + analyysi
cut -f1,2            # ota ensimmäinen ja toinen
cut -d"+" -f1|       # heitä analyysi pois
uniq|                # lyö tuplamuodot yhteen
sort|                # laita aakkosjärjestykseen
uniq -c|             # laske muotoja
sort -nr|            # järjestää määrän mukaan
cut -c6-|            # ota numerot pois
nobfkv|              # käänne kveeniksi
grep "?"|            # poimi tuntemattomat
cut -f1|             # muodot vain kerran
grep '[a-z]'|        # vain ne, joilla on vähintään yksi kirjain
tr '\n' ','|         # lista muutetaan yhdeksi riviksi
sed 's/,/, /g;'|     # lisätään väli pilkun jälkeen
see                  # ja heitetään subethaeditiin
```

## Missinglists

Missinglists:

- *Vanha preprosessointi*

```
ccat -l fkv converted/fkv/|preprocess|ufkv|grep '+?'|cut -f1|sort|uniq -c | sort -nr > fkv.missing.191021
```

- *Uusi preprosessointi:*

```
ccat -l fkv converted/fkv/|hfst-tokenize -cg ~/langs/lang-fkv/tools/tokenisers/tokeniser-disamb-gt-desc.pmhfst|grep ' '?|cut -d'"' -f2|sort|uniq -c |sort -nr | less (funker 12.02.21)
```

- `ccat -l fkv converted/fkv/|preprocess|ufkv|grep '+?'|cut -f1|sort|uniq -c | sort -nr | less` (i freecorpus)
- `cat kvensktext.txt|preprocess|ufkv|grep '+?'|cut -f1|sort|uniq -c | sort -nr | less` (i egen fil)
- `ccat -l fkv converted/fkv/|grep 'miitä'| less` (finn kontekst)

fkv:ssa:

```
./configure --with-hfst --enable-tokenisers --enable-reversed-intersect --enable-dialects  
make -j
```

### Gammelmåte

- `cd freecorpus`
- `ccat -l fkv converted/fkv/|preprocess|ufkv|grep '+?'|cut -f1|sort|uniq -c | sort -nr > fkv.missing.191021`
- see fkv.missing.191021

### Nymåte

- `ccat -l fkv converted/fkv/|hfst-tokenize -cg $GTHOME/langs/fkv/tools/tokenisers/tokeniser-disamb-gt-desc.pmhfst|grep ' '?|cut -d'"' -f2|sort|uniq -c |sort -nr > fkv.missing.191021`
- see fkv.missing.191021

Tokenize må være aktivert via confi:

```
./configure --with-hfst --enable-tokenisers --enable-reversed-intersect --enable-dialects
```

```
-----  
lang-fkv$ hufkv  
huonet  
huonet huonet+N+Sg+Nom 0,000000
```

```
lang-fkv$ hdfkv  
huonet+N+Sg+Nom  
huonet+N+Sg+Nom huone 0,000000  
huonet+N+Sg+Nom huonet 0,000000  
-----
```

```
lang-fkv$ nobfkv  
bil  
bil piili 0,000000
```

## Generere/oppdatere nobfkv og fkvnob:

```
cd langs/giella-core/dicts/  
rm nobfkv/bin/*.lexc  
rm fkvnob/bin/*.lexc  
make -f make-bildict SLANG=nob TLANG=fkv TNUM=all  
make -f make-bildict SLANG=fkv TLANG=nob TNUM=all
```

# Hvor mange ord er det i ordboka?

tell alle ord for hver ordbok, antall ord: `cat src/*.xml|grep '<l '|wc -l`

## Historikk:

`cat fkvnob/src/*.xml|grep '<l '|wc -l`  
9139

`cat nobfkv/src/*.xml|grep '<l '|wc -l`  
9032

^ 24. april 2020

Tuomas:dicts thomas\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
9651

Tuomas:dicts thomas\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
9577

^ 23. des 2020

`dicts thomas$ cat fkvnob/src/*.xml|grep '<l '|wc -l`  
10189

`dicts thomas$ cat nobfkv/src/*.xml|grep '<l '|wc -l`  
10179

^ 17. mars 2021

thomasbk:dicts thomas\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
10236

thomasbk:dicts thomas\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
10231

^ 15. nov 2021

Tuomas:dicts thomas\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
10273

Tuomas:dicts thomas\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
10299

^31. jan 2022

thomasbk:dicts thomasbk\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
10401

thomasbk:dicts thomasbk\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
10397

^8. nov 2022

Tuomas:dicts thomas\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
10745

Tuomas:dicts thomas\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
10663

^29. nov 2022

thomasbk:dicts thomasbk\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
12672

thomasbk:dicts thomasbk\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`  
11851

^01. apr 2023

thomasbk:dicts thomasbk\$ `cat fkvnob/src/*.xml|grep '<l '|wc -l`  
14941

thomasbk:dicts thomasbk\$ `cat nobfkv/src/*.xml|grep '<l '|wc -l`

13389  
^06. okt 2023

thomasbk:dicts thomasbk\$ cat fkvnob/src/\*.xml|grep '<l '|wc -l  
15016  
thomasbk:dicts thomasbk\$ cat nobfkv/src/\*.xml|grep '<l '|wc -l  
13633  
^11. okt 2023

thomasbk:dict-fkv-nob thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
15220  
thomasbk:dict-nob-fkv thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
13821  
^07. nov 2023

tromso-nat-guest-737:dict-fkv-nob thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
15461  
tromso-nat-guest-737:dict-nob-fkv thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
14072  
29/11-23

thomasbk:dict-fkv-nob thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
15649  
thomasbk:dict-nob-fkv thomasbk\$ cat src/\*.xml|grep '<l '|wc -l  
14304  
14/02-24

dict-fkv-nob\$ cat src/\*.xml|grep '<l '|wc -l  
15661  
dict-nob-fkv\$ cat src/\*.xml|grep '<l '|wc -l  
14314  
sommeren 2024

## Hvor mange ord er det i korpus?

### Historikk:

freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
368315 (10. jan 2021)

freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
371121 (11. jan 2021)

freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
403588 (17. mars 2021)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
406279 (12. mai 2021)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
412784 (03. juli 2021)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
423028 (01. sept 2021)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
427847 (19. okt 2021)

dhcp3398-stud:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w

5 av 11

431100 (11. nov 2021)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
433773 (31. jan 2022)

thomasbk:freecorpus thomas\$ ccat -l fkv converted/fkv/|wc -w  
444248 (16. mai 2022)

thomasbk:freecorpus thomasbk\$ ccat -l fkv converted/fkv/|wc -w  
444075 (8. nov 2022 reset maskin)

thomasbk:freecorpus thomasbk\$ ccat -l fkv converted/fkv/|wc -w  
450729 (10. mars 2023)

thomasbk:freecorpus thomasbk\$ ccat -l fkv converted/fkv/|wc -w  
461821 (11. mars 2023)

thomasbk:corpus-fkv thomasbk\$ ccat -l fkv converted/|wc -w  
472808 (6. okt 2023)

thomasbk:corpus-fkv thomasbk\$ ccat -l fkv converted/|wc -w  
508837 (5. des 2023)

thomasbk:corpus-fkv thomasbk\$ ccat -l fkv converted/|wc -w  
495527 (14. feb 2024)

thomasbk:corpus-fkv thomasbk\$ ccat -l fkv converted/|wc -w  
499242 (12. jun 2024)

---

## Vanlig korpus pluss Børselv:

thomasbk:corpus-fkv thomasbk\$ ccat -l fkv converted/|wc -w  
499242 (12. jun 2024)

thomasbk:corpus-fkv-x-closed thomasbk\$ ccat -l fkv converted/|wc -w  
616573 (Børselv lagt til her: corpus-fkv-x-closed)

**Yhtheensä: 1.115.815**

## Finn ord som finnes i en ordbok, men mangler i den andre

```
cat fkvnob/src/*.xml | grep '<t '|
cut -d"<" -f2|cut -d">" -f1
| preprocess
| nobfkv | grep '?'
```

Original:

```
cat fkvnob/src/*.xml | grep '<t '| cut -d"<" -f2|cut -d">" -f1 | preprocess | nobfkv |
grep '?'
```

12.10.23:

6 av 11

```
cat fkvnob/src/V_fkvnob.xml | grep '<t ' | cut -d"<" -f2|cut -d">" -f2 | tr " " "_"|
nobfkv | grep '?' |
cat fkvnob/src/N_fkvnob.xml | grep '<t ' | cut -d"<" -f2|cut -d">" -f2| tr " " "_"|
nobfkv|grep '?'|
```

## Script som automatisk lager xml-oppsettet til ordboka fra en tabliste:

```
cat Klart.txt | sed "s/ /N /" | perl ~/main/words/dicts/fkvnob/scripts/c2x.pl >
testing.txt
```

- Lage reversert (erstatt TAB med mellomrom først)  
cat test.txt | sed -e 's/([^\ ]\*) \*([^\ ]\*)/2 \1/' > reversert.txt

```
listemedord | fkvnob | grep " " | sed "s/ /N /" | perl fkvnob/scripts/c2x.pl |
less
```

```
fkvnob | grep " " | sed "s/ /N /" | perl fkvnob/scripts/c2x.pl | less
```

-----

```
cat nobfkv/src/N_nobfkv.xml | grep '<t ' | less (de oversatte)
cat nobfkv/src/N_nobfkv.xml | grep '<l ' | less (de norske)
```

hele:

```
cat nobfkv/src/N_nobfkv.xml | grep '<t ' | cut -d"<" -f2|cut -d">" -f2 | preprocess |
fkvnob | grep '?'|cut -f1 | sort | uniq -c | sort -nr | cut -c6- | hunob | cut -f2 | cut
-d"+" -f1 | uniq | grep "[a-z]" | fkvnob | grep "?" | cut -f1 | fkvnob | grep " " | less
```

- **Kjøre ordliste gjennom ordboka:** cat filnavn.txt |cut -f1|fkvnob|grep "?"|cut -f2 | |
- **Reversere:** cat filnavn.txt | sed -e 's/([^\ ]\*) \*([^\ ]\*)/2 \1/' | |
- **Lage xml:** cat filnavn.txt | sed "s/ /N /" | perl ~/main/words/dicts/nobfkv/scripts/c2x.pl | | **(og bytt til fkvnob)**

## Legge til ord fra sanakirja til lexc

```
fkvnob thomas$ cat src/N_fkvnob.xml |grep '<l ' |cut -d">" -f2|cut -d"<" -f1|grep -v " " |ufkv|grep
"?"|cut -f1,2|tr '\t' ':' | rev|cut -c3-|sort|rev|less
```

```
fkvnob thomas$ cat src/N_fkvnob.xml |grep '<l ' |cut -d">" -f2|cut -d"<" -f1|grep -v " " |ufkv|grep
"?"|cut -f1,2|tr '\t' ':' | rev|sort|rev|less <--- denne er bra, og ganske klar til å legge til i lecx
```

```
trond$ cat src/V_fkvnob.xml |grep '<l '|cut -d">" -f2|cut -d"<" -f1|grep -v ' '|ufkvNorm|  
grep "?"  
dette er den gamle
```

=

```
xfst: cat ~thomas/main/words/dicts/fkvnob/src/N_fkvnob.xml |grep '<l '|cut -d">" -f2|cut -d"<"  
-f1|grep -v " " |ufkv|grep "?"|cut -f1,2|tr '\t' ':' | rev|sort|rev|less
```

```
hfst: cat ~thomas/main/words/dicts/fkvnob/src/N_fkvnob.xml |grep '<l '|cut -d">" -f2|cut -d"<"  
-f1|grep -v " " |hufkv|grep "?"|cut -f1,2|tr '\t' ':' | rev|cut -c3-|sort|rev|less
```

## Tastatursnarveier

**find next: cmd+g**

**replace and find next: ctrl+cmd+g**

dubletter - doble, flere enn  
uniq -d anna mulle jos on enemmæn kuin yksi d  
uniq -c | sort -nr (enemmæn kuin kaks)

```
grep -A10 (vis 10 linjer etterpå)  
grep -A10 haug nobfkv/src/*_nobfkv.xml
```

```
grep -v Prop (uten navn)
```

**ctrl+K (fjern alt etter kursor)**

**ctrl+D (fjern enkeltbokstav etter kursor)**

Delete previous character = Delete or Control+H  
Delete next character = Forward Delete key, or FN+Delete or Control+D  
Delete previous word = Option+Delete  
Delete next word = Option+FN+Delete  
Delete to start of line = Command+Delete  
Delete remainder of paragraph = Control+K  
Select back to the start of paragraph and delete = Shift+Option+Up then Delete, or  
Shift+Control+A then Delete  
Select to the end of paragraph and delete = Shift+Option+Down then Delete, or Shift+Control+E  
then Delete  
Cut = Command+X

## Hvordan klonere repositorie (sjekke ut til egen maskin)

To måter å gjøre det på:

```
git clone https://github.com/giellalt/dict-fkv-nob
```

og

```
git clone git@github.com:giellalt/dict-fkv-nob
```

gamle svn up = tre kommandoer for å gjøre akkurat det samme som gamle svn up:

**git stash, git pull --rebase, og git stash pop**



**git add**

**git commit**

**angre commit (fjern den siste kommittede)**

git reset --hard HEAD^1

**git push**

```
thomasbk:~ thomasbk$ cd dict-fkv-nob/  
thomasbk:dict-fkv-nob thomasbk$ open -a tower .  
thomasbk:dict-fkv-nob thomasbk$
```

**Ved Pull-knappen:** huk av på **Rebase instead of merge**

1. git clone https://github.com/giellalt/corpus-fkv-orig-x-closed
2. cd corpus-fkv-orig-x-closed
3. open -a tower .

Kjør disse hvis sjekket ut nytt språk:

1. ./autogen.sh
2. ./configure
3. make -j
4. make install (viktig for korpus)

## Korpuskommandoer

kjør make install i fkv (ikke bare autogen, configure og make)

**add\_files\_to\_corpus -d orig/fkv/news/ruijankaiku --name ruijan-kaiku.no\_laft-bak-loe.html  
https://www.ruijan-kaiku.no/laft-bak-loe-hirsinurkka-kajan-takana/**

Added /Users/thomas/freecorpus/orig/fkv/news/ruijankaiku/ruijan-kaiku.no\_laft-bak-loe.html

**add\_files\_to\_corpus -p /Users/thomas/freecorpus/orig/fkv/news/ruijankaiku/ruijan-  
kaiku.no\_laft-bak-loe.html -l nob --name ruijan-kaiku.no\_laft-bak-loe.html https://  
www.ruijan-kaiku.no/laft-bak-loe-hirsinurkka-kajan-takana/**

```
freecorpus thomas$ convert2xml /Users/thomas/freecorpus/orig/fkv/news/ruijankaiku/ruijan-  
kaiku.no_laft-bak-loe.html  
freecorpus thomas$ convert2xml /Users/thomas/freecorpus/orig/nob/news/ruijankaiku/ruijan-  
kaiku.no_laft-bak-loe.html
```

```
parallelize -l2 fkv converted/<den norske fila>  
parallelize -l2 fkv converted/nob/news/ruijankaiku/ruijan-kaiku-25-ar.html.xml
```

(reparallelize konverterer til xml og kjører parallelize, så hvis du allerede har kjørt convert2xml etter endringene, kan du bare kjøre parallelize på nytt i stedet for reparallelize):  
reparallelize kjøres på .html-fila, og den finner tilbake til originalfilene og viser dem øverst  
(**detektivarbeideren!**)

reparallelize prestable/tmx/nob2fkv/news/ruijankaiku/ruijan-  
kaiku\_aikamoinen\_kartano.html.tmx.html

1. parallelize
2. redigere noe
3. reparallelize

## Greppe ord som mangler i ordboka uten å miste oversettelsene / resten av tekstlinja:

- `cat ~/Desktop/sannoi_3.txt |cut -f1|fkvnob|grep "?"|cut -f1|sort|uniq > inc/  
puuttuvat-sannoi_230220.csv`
- `for i in `cat inc/puuttuvat-sannoi_230220.csv` ; do grep "^$i" ~/Desktop/  
sannoi_3.txt >> inc/puuttuvat-sannoi_230220.dict.csv ; done`

Script

```
cat fil.txt | sed "s/ / /" | perl ~/main/words/dicts/fkvnob/scripts/c2x.pl ||
```

```
antiword sannoi.doc |./sannoi.sed|tr "\n" TM|sed "s/TM /g;"|tr TM "\n" >  
sannoi_3.txt
```

```
cat filnavn.txt | tr "- \n" " " | I (bytt ut alle linjeskift med mellomrom)
```

## Speller-arbeid:

nuvviDspeller (finn info i Online speller)

<https://divvun.org/proofing/online-speller.html>

ll tools/spellcheckers/\*.txt (sjekk filer som kan redigeres)

Se på forslag:

```
thomasbk$ hfst-ospell -S -n 5 tools/spellcheckers/fkv.zhfst
```

kirjalinen

"kirjalinen" is NOT in the lexicon:

Corrections for "kirjalinen":

viralinen 24.244946

kirjaluinen 25.324387

Sjekk for et spesifikt ord (kalaa):

```
e kalaa |hfst-ospell -S -n 10 tools/spellcheckers/fkv.zhfst
```

"kalaa" is NOT in the lexicon:

Corrections for "kalaa":

kansa 7.182723

alas 8.165504

alla 8.422414

kallaa 8.727074

alan 8.843147

ala 9.650238

Farge-TV:

10 av 11

- **sh devtools/test\_ospell-office\_suggestions.sh**
- legg til skrivefeil i typos.txt
- endre verdier i strings.default.txt
- lagre og kjør make, før du gjør første punkt på nytt

(hvis ord som får rødstrek mangler i analysatoren, er det bra å legge til! Mari fikk rødstrek på «puolikova» i online speller)

(de viktigste filene man kan redigere er **typos.txt**, **editdist.default.txt**, **final\_strings.default.txt** og **words.default.txt**)

```
542 ls -l tools/spellcheckers/fit.zhfst
544 e kalaa |hfst-ospell -S -n 10 tools/spellcheckers/fkv.zhfst
546 see tools/spellcheckers/spellercorpus.sort.txt
547 see tools/spellcheckers/weights/spellercorpus.raw.txt
548 see tools/spellcheckers/weights/spellercorpus.clean.txt
```

## ----- Spellercorpus

see tools/spellcheckers/spellercorpus.\*

```
-----
Sjekk for et spesifikt ord (kalaa):
e kalaa |hfst-ospell -S -n 10 tools/spellcheckers/fkv.zhfst
"kalaa" is NOT in the lexicon:
Corrections for "kalaa":
kansa  7.182723
alas   8.165504
alla   8.422414
kallaa 8.727074
alan    8.843147
ala     9.650238
```

-----  
Sjekk opp tall: (e = echo)

```
lang-fit thomasbk$ e 12 | hfst-lookup src/fst/transcriptions/transcriptor-numbers-
digit2text.filtered.lookup.hfstol
> 12 kakstoista
```

```
lang-fit thomasbk$ e 7.3. | hfst-lookup src/fst/transcriptions/transcriptor-date-
digit2text.filtered.lookup.hfstol
> 7.3. maaliskuun seitsemäs päivä
```